

Systemes d'intégration de ressources hétérogènes et distribuées

**0. Un exemple d'un système d'intégration de données (Voir fichier
Complément SI)**

1. Introduction & Contexte : Intégration virtuelle de données

2. Architecture Médiateur-Adaptateur

3. Problèmes posés par la conception d'un système d'intégration

4. Principe d'évaluation et d'optimisation d'une requête

1. Introduction : Contexte, Motivation et Objectif

Ressources informatiques sont connectées à l'Internet

==> Accessibles à travers des protocoles de comm. TCP/IP, HTTP

Ressources : {Données, Programmes applicatifs } que le propriétaire souhaite partager avec d'autres utilisateurs.

• Caractéristiques des ressources :

◆ Autonomes :

Développées et maintenues en isolation, et indépendamment des applications pouvant les utiliser

==> Capacités de traitement d'une ressource sont décidées uniquement par leurs propriétaires

◆ Distribuées :

Ressources pertinentes d'un même sujet se trouvent souvent sur des sites distants

◆ Hétérogènes :

Structures de données (relationnel, objet, XML, HTML, ...)

Capacités de traitement de requêtes.

• Contexte d'intégration virtuelle à grande échelle

◆ Approche alternative : Entrepôt de Données ED

consiste à répliquer toutes les sources dans un seul site, sur lequel sont évaluées toutes les requêtes.

◆ Avantages de l'approche ED : Meilleure(s)

- Performances : absence de comm. Inter-sites
- Fiabilité : sources répliquées sont sous le contrôle d'un site

◆ Inconvénients de l'approche ED :

- Impossible de dupliquer toutes les ressources d'intérêt sur un site, pour des raisons de confidentialité, de droits intellectuels ou sécurité
- Passage à l'échelle est difficile lorsqu'on utilise un grand nombre de ressources
- Programmes dépendent souvent de l'env. particulier du site de leur propriétaire et donc ne peuvent pas être utilisées ailleurs.

➡ Les ressources seront exploitées à partir de leurs sites d'origines

2. Architecture Médiateur-Adaptateur M-A (Rappel)

● Rôle d'un Médiateur :

- interagir avec les ressources distribuées et avec les appl. qui demandent d'accéder à l'info intégrée
- fournit un point d'accès unique et uniforme aux ressources
- fournit une interface d'interrogation que les appli. peuvent utiliser
- la présence de couche intermédiaire fournie par le médiateur permet aux appli. utilisant l'info. intégrée d'être indépendantes par rapport à l'autonomie et à l'évolution des ressources

● Rôle d'un Adaptateur

- agit comme un intermédiaire entre des ressources et des médiateurs
- cache aux médiateurs le format interne et la mise en œuvre de leurs ressources
- fournit aux médiateurs une description de ressources dans le format du médiateur
- accepte de traiter des sous-requêtes sur ces ressources (à la demande du médiateur)
- le traitement de requêtes dans un système M-A est divisé entre les adaptateurs et les médiateurs
- connecté directement aux diverses ressources via une interface adaptée à chaque ressource
- exporte :
 - des méta-données concernant les ressources, par ex. . description du contenu de chaque source de données
 - une description des capacités de traitement de requêtes, et
 - des statistiques sur des données ou des paramètres de coût associés à leurs capacités de traitement

● Schéma Local et Schéma Global

- l'interface uniforme entre les adaptateurs et les médiateurs est basée sur un modèle de données commun dans lequel toutes les ressources sont décrites
- chaque adaptateur présente au médiateur un schéma local

- le médiateur fournit aux applications utilisant ses services un schéma global

3. Problèmes posés lors de la conception d'un système d'intégration basé sur une architecture M-Adaptateurs

- Un modèle commun doit être établi pour les ressources hétérogènes :

- riche pour modéliser les aspects intéressantes des ressources
- évolué pour permettre l'optimisation de requêtes

- Un adaptateur est nécessaire pour chaque type de ressource, afin de la présenter sous le modèle commun choisi

- la mise en œuvre des adaptateurs est une tâche difficile
- sa difficulté est un obstacle majeure pour le développement d'application d'intégration de ressources à grande échelle

- Conception d'un schéma global :

- par un processus d'intégration de schéma
 - entraîne la résolution des différences de domaines
 - l'identification des entités communes dans des sources de données différentes (utilisation des clés communes)

- Méthodologies de traitement de requêtes

1. la requête, exprimée/schéma global, doit être re-formulée en termes de schémas locaux (schémas des adaptateurs)
2. le médiateur décompose la requête ainsi re-formulée dans
 - a. plusieurs sous-requêtes à envoyer aux adaptateurs et
 - b. quelques opérations que le médiateur va exécuter sur les résultats des sous-requêtes des adaptateurs
3. Optimisation de req. distribuées (décomposition n'est pas unique)
4. les sous-requêtes sont envoyées aux adaptateurs pour les exécuter
5. les résultats des sous-requêtes des adaptateurs sont fournis au médiateur, qui exécute certaines opérations nécessaires et retourne le résultat complet.

- Remarques : Dans le cas d'un SI à plusieurs médiateurs

- les étapes ci-dessus sont les mêmes
- si plusieurs médiateurs participent à l'exécution de la requête, ils pourraient se voir attribuer des sous-requêtes à traiter (Comme les adaptateurs)
- un seul médiateur coordonne l'exécution d'une requête.

4. Evaluation et optimisation de requêtes dans un système d'intégration

4.1. Principe d'évaluation (voir pages séparées)

4.2. Optimisation : = <Espace de recherche, Stratégies de recherche, Modèle de coûts>

● Espace de recherche

- Nature de l'espace de recherche : arbres linéaires et ramifiés
- Type de requête
- Localisation des ressources utilisées par la requête
- Capacités limitées de traitement de requêtes des adaptateurs
 - Ex. Adaptateur du site Web de type Pages Jaunes PJ Exécute une classe de requêtes assez restreintes
- Classification des capacités de traitement de requêtes.
 - Capacités de traitement de requêtes positives
Ex . SGBDR classique
 - Capacités de traitement de requêtes. négatives
 - l'adaptateur peut imposer des restrictions lors de l'accès aux ressources qu'il gère
 - Ex : le service Web PJ, on peut exiger un nom et un code postal afin d'obtenir le Numéro de Tél.
 - Certaines requêtes pourraient être rejetées par le système : car l'adaptateur ne l'accepte pas et le médiateur n'a pas accès aux sources de données

● Stratégies de recherche

La présence des capacités limitées des sources, implique une modification de la stratégie de recherche de l'optimiseur afin d'explorer uniquement l'espace des plans faisables.

➡ Différentes sources de difficultés dans l'exécution de requêtes :
< Distribution, Hétérogénéité, Contrôle >

- **Distribution**

==> **Pb. de comm. : Min (Coûts de Comm.)**

- Application des techniques d'exécution validées dans les SGBDR : Jointure distribuée, Jointure à base de semi-jointure,

- **Hétérogénéité des capacités de traitement de requêtes**

- Adaptation aux capacités de l'adaptateur (traduction de la sous requête dans le langage de l'adaptateur)
- Intégration des opérateurs adaptatifs en raison de l'autonomie des sites d'exécution (ré-optimisation, construction d'un nouveau plan,)

- **Manque de contrôle sur les sites distants :**

- Difficulté de transférer des prog. d'un site S_i vers un site S_j ➔ Obligé(s) d'envoyer les arguments du prog sur le site où le prog. peut être exécuté.

○

● **Modèle de coûts**

- **Difficulté d'obtenir des statistiques sur les données :**

- Nature de ressources utilisées : < CPU, RAM, BP (R & D), SD >
- Restrictions sur l'accès à ces ressources
- Changements fréquents dans les contenus des SD
- Instabilité des ressources de calcul RC ➔ impact sur les valeurs des paramètres modélisant les RC

- **Formules de Coûts FC :**

- Chaque écrivain d'adaptateur peut fournir des FC pour son propre adaptateur ou
- Une FC générique peut être utilisée pour tous les adaptateurs et calibrée par l'exécution d'un ensemble de requêtes de calibrage.

4.3. Opérateurs relationnels à accès restreint

Soit une source de données modélisée sous forme d'une BD relationnelle composée de 2 relations : R (nom^f, adresse^f, profession^f) et S (nom^b, num_tel^f) avec :

<attribut>^f signifié que la valeur de l'attribut est libre (free) pouvant être donnée en entrée (e.g. dans la clause Where du langage SQL) ou affichée /sélectionnée (en sortie) et

<attribut>^b signifié que les valeur de l'attribut doivent être instanciées (bound) et l'attribut (instancié) ne peut être utilisé qu'en entrée comme filtre (e.g. dans la clause Where du langage SQL).

Remarque : Dans SGBD relationnel classique (requêtes positives) tous les attributs sont tous implicitement de type « libre », comme la relation R ci-dessus.

1. Opérateur de Sélection

La requête "Selection num-tel From S,where nom= »Durand »" est valide (ou faisable). Cependant, la requête "Selection nom from S,where num-tel= 11111 » n'est pas valide (ou rejetée), car, le type de "nom" est « bound » (instancié).

2. Opérateur de jointure, appelée Jointure dépendante

Donner/afficher le num-tel et l'adresse des abonnés ?

Dans ce cas, comme les types d'attributs (valeurs) de jointure entre R et S sont respectivement « libre » et « instancié » on doit alors faire R Jointure S : on part de R pour explorer les tuples de S. Mais, on ne peut pas faire S Jointure R : on part de S pour explorer les tuples de R, car les valeurs de nom^b doivent être, d'abord, instanciées. En conséquence, la jointure de deux relations dans un système d'intégration pourrait ne pas être commutative. Cela dépendra du type d'attribut « libre » ou « instancié ».