

*Université Paul Sabatier, Toulouse 3*

## *Bases de Données Parallèles*

### *Méthodologies d'optimisation - parallélisation de requêtes décisionnelles*

- I. Avantages et limites des systèmes relationnels*
- II. Introduction aux BD parallèles*
- III. Parallélisation des opérateurs relationnels*
- IV. Méthodologies d'optimisation-parallélisation de req. décisionnelles*
- V. Optimisation des coûts de communication dans les BDP*
- VI. Conception d'un modèle de coût*

*A. Hameurlain <hameur@irit.fr>*

*Université Paul Sabatier, Lab. IRIT,  
118 Rte de Narbonne  
31062 Toulouse - France*

# **I RAPPELS : SYSTEMES RELATIONNELS**

## **1. DEFINITION & TERMINOLOGIE**

### **☛ MODELE RELATIONNEL [CODD 1970 & 1979]**

- **RELATION**  $\subset D_1 \times D_2 \times \dots \times D_n$       **D : Domaine**
- **TUPLE** : ELEMENT D'UNE RELATION
- **ATTRIBUT** --> **DOMAINE**

**SCHEMA RELATIONNEL :**

**UN SCHEMA DE RELATION :**

**NOM DE LA RELATION**  
**LISTE DES ATTRIBUTS**  
**[CONTRAINES D'INTEGRITE]**

**SCHEMA DE RELATION <---> PARTIE INTENTIONNELLE**

**LES TUPLES DE LA REL. <--> PARTIE EXTENSIONNELLE**

### **☛ LANGAGE DE DEFINITION DE DONNEES/SCHEMAS**

### **☛ LANGAGES RELATIONNELS : SQL, QUEL, QBE,...**

### **☛ DEFINITION DES VUES**

### **☛ PROGRAMMATION DES APPLICATIONS : SQL +{/C/C++/ADA/Java/,..**

## 2. AVANTAGES DES SYSTEMES RELATIONNELS

- ☛ **SIMPLICITE DES CONCEPTS ET DU SCHEMA**
- ☛ **INDEPENDANCE DONNEE-PROGRAMME**
  - **INDEPENDANCE LOGIQUE**
  - **INDEPENDANCE PHYSIQUE**
- ☛ **LANGAGES RELATIONNELS : DECLARATIFS**
  - **SPECIFIER LES DONNEES RECHERCHEES**
  - **SANS DONNER LE CHEMIN D'ACCES**
  - ➔ **OPTIMISATION DE TRAITEMENT DES REQUETES**
    - ⇒ **STRATEGIES D'OPTIMISATION**
    - ⇒ **METHODES D'ACCES**
- ☛ **CONCEPT DES VUES**
  - **DEFINITION DES RELATIONS DEDUITES(VIRTUELLES)**
  - **AVANATAGES :**
    - ➔ **SECURITE ET CONFIDENTIALITE**
    - ➔ **AMELIORE L'INDEPENDANCE LOGIQUE**
    - ➔ **SIMPLICITE D'EXPLOITATION**
  - **AUGMENTER LA PUISSANCE DES LANGAGES REL.**
- ☛ **MANIPULATION ENSEMBLISTE DES DONNEES**
  - ➔ **EXPLOITATION DU PARALLELISME**
    - ⇒ **Haute Performance**
- ☛ **Objectif :**
  - **Minimiser le temps de réponse TR d'une requete :  $T_{cpu} + T_{E/S} + T_{com}$**
  - **Maximser l'exploitation des ressources : <CPU, Disque , Réseau, Mémoire>**
- ☛ **gérer de manière efficace et économique :**
  - **l'allocation des ressources**
  - **les coûts de communication : données, contrôle**

## ***II. Introduction aux bases de données parallèles***

### ***1. Motivation***

#### **☛ *Langages relationnels : déclaratifs***

*Modèle d'exécution monoprocesseur* ⇒

*Modèle d'exécution multiprocesseur*

⇒ *aucun impact sur les programmes d'application*

⇒ *Meilleure utilisation des compétences des programmeurs*

#### **☛ *Nature du parallélisme : <Explicite, Implicite>***

⇒ *Les processus : Optimisation - Parallélisation - Allocation de ressources sont TRANSPARENTS aux programmeurs*

### ***2. Objectifs des BD parallèles***

☛ *Meilleur Coût / Performance par rapport à la solution gros systèmes (DPS8 / GCOS, IBM 30390 / VMS, ...)*

☛ *Haute performance :*

• *Minimiser le temps de réponse*

• *Maximiser l'utilisation des ressources du système //*

☛ *“ Scalability ” : Dimensionnement évolutif*

• *Ajout de nouvelles ressources (CPU, Disque, Mémoire, Réseau)*

• *Ajout de nouveaux utilisateurs*

⇒ *Sans perte de performance*

☛ *Disponibilité des données (en cas de pb sur des noeuds)*

### **3. Modèles d'Architectures Parallèles**

#### **☛ Classes d'Architectures Parallèles : Mémoire et Processeurs**

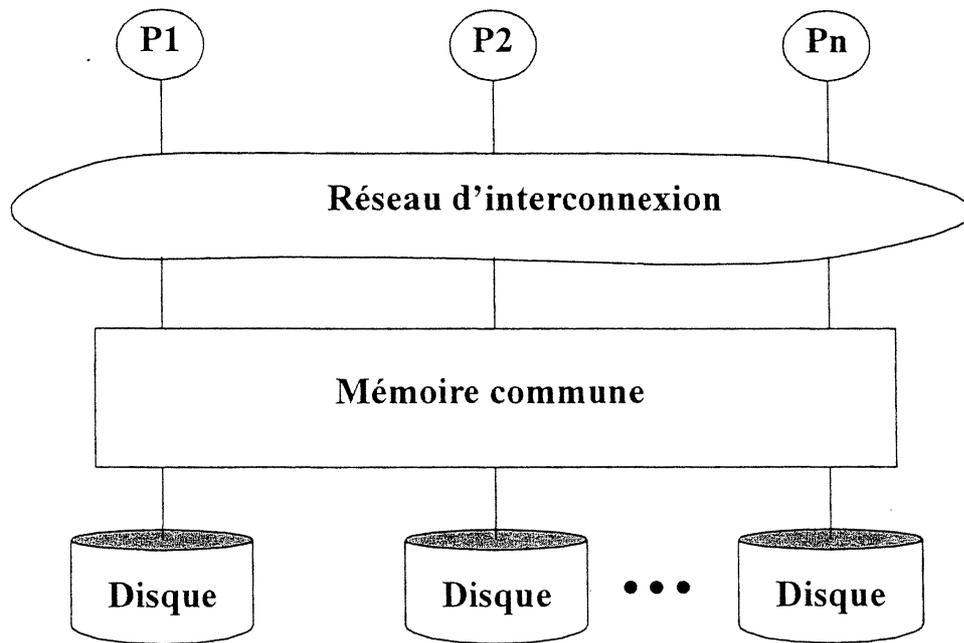
- **Modèle d'exécution SIMD** (*Single Instruction Multiple Data Stream*)
- **Modèle d'exécution MIMD** (*Multiple Instruction Multiple Data Stream*)

*En fonction de l'organisation des données en mémoire :*

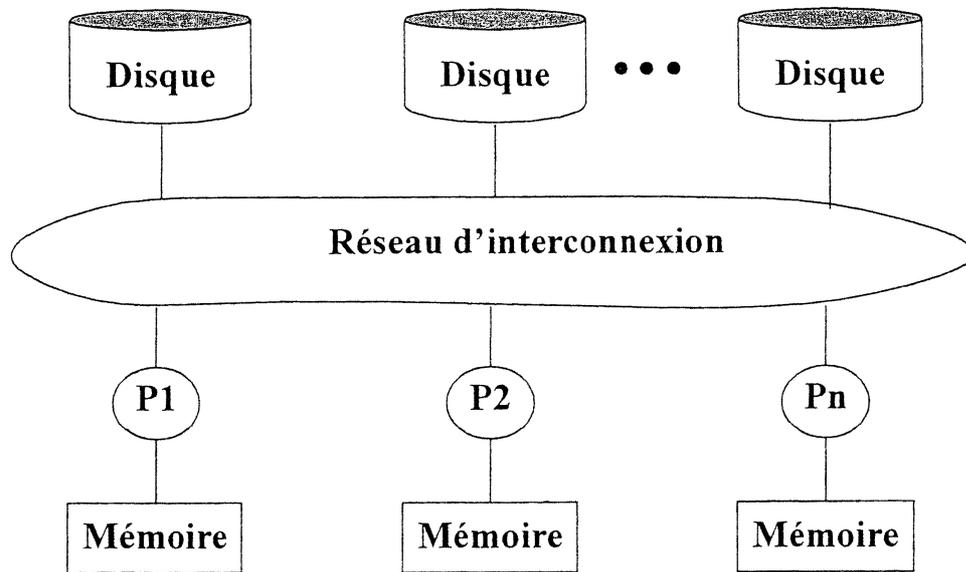
- ⇒ *Multiprocesseur à mémoire commune (Couplage fort)*
- ⇒ *Multiprocesseur à mémoire distribuée (Couplage faible)*

#### **☛ Contexte Bases de Données : Mémoire, Processeurs et Disques**

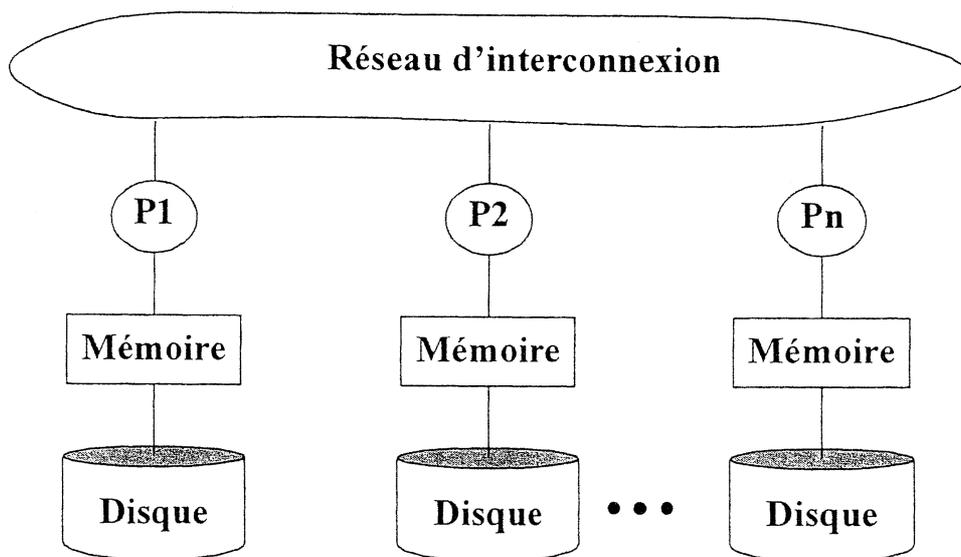
- *SGBD Parallèles basés sur des Arch. Mult. à Mém. Commune*
- *SGBD Parallèles basés sur des Arch. Mult. à Disques partagés*
- *SGBD Parallèles basés sur des Arch. Mult. à Mém. Dist.*



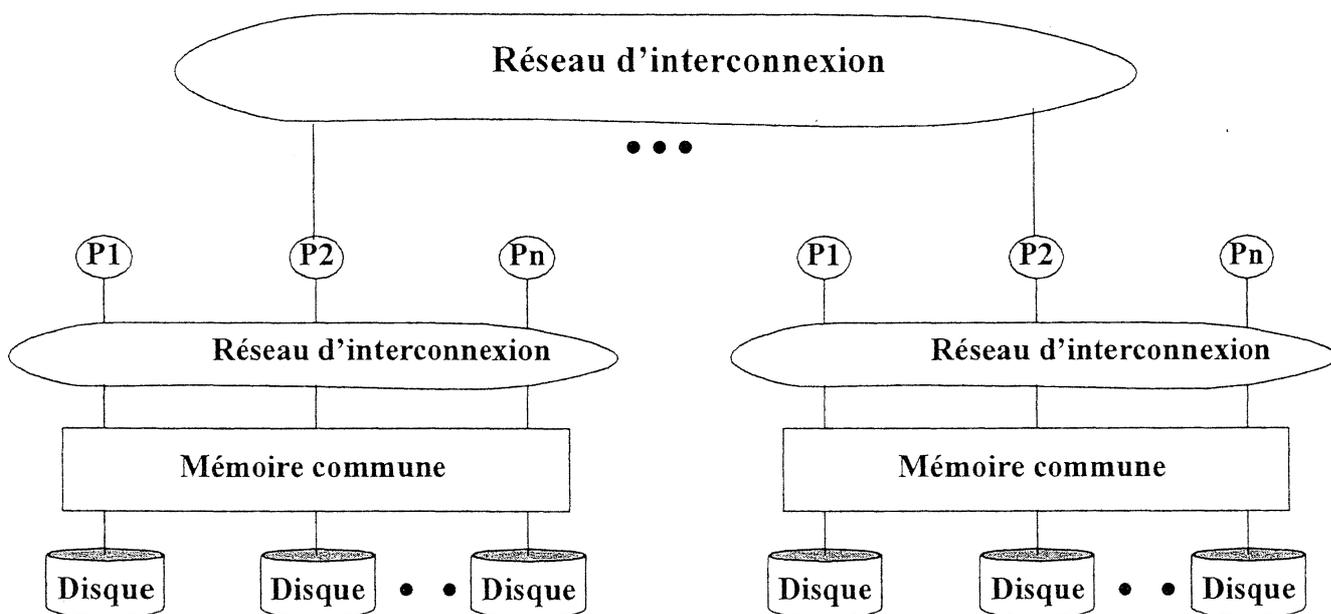
*Architecture à Mémoire Commune*



*Architecture à disques partagés*



*Architecture à Mémoire Distribuée*



*Architecture Hybride*

*(i) Avantages et Inconvénients des Architectures (voir en TD)*

- ☛ *à Mémoire Distribuée*
- ☛ *à Mémoire Commune*

*(ii) Principaux produits et prototypes*

☛ *à mémoire distribuée*

- *Teradata : DBC/1012 Database computer*
- *Tandem NonStop SQL*
- *Serveur Parallèle ORACLE ( $\geq V7$ , 1994)*
- *DB2 (SP2 et SPQS (IBM))*
- *DSA/PDQ Informix (1994)*
- *Gamma : Dewitt et al. USA [Dew 90]*
- *Bubba : Boral et al. USA [Bor 90]*
- *Oracle /Supernode : PARSYS*
- *Prisma/DB [Ape 92]: Phillips et univ. Thewente (NL)*

☛ *à mémoire commune*

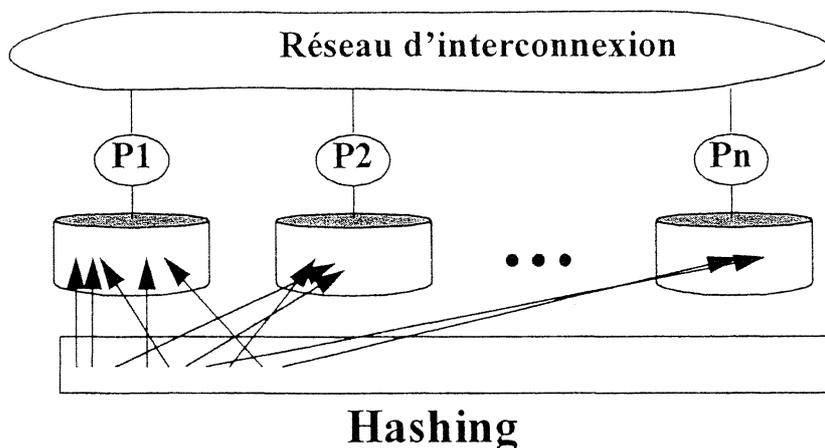
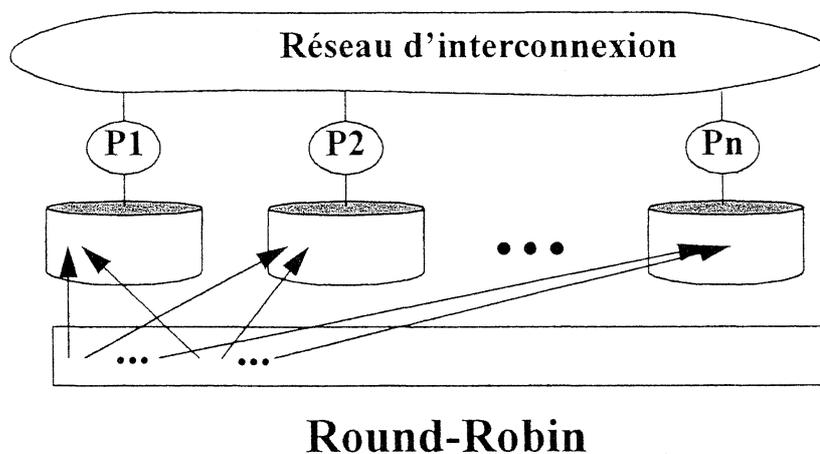
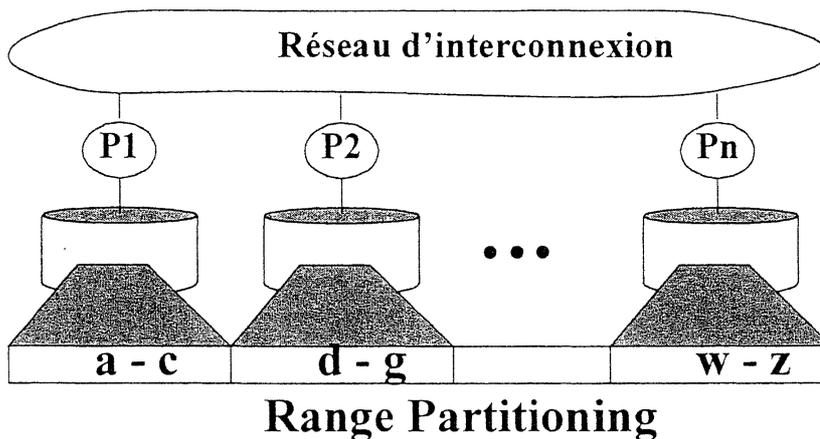
- *XPRS : Stonebraker et al., Univ. Berkley [Sto 88]*
- *DBS3 /KSR1 [Cas 94]: Inria & Bull (Mém. Log. Partagée)*
- *Volcano (USA) [Gra 90]*
- *Disques Partagés :IMS Data Sharing (IBM),  
ORACLE V7 Parallel Server*

#### 4. Approches et méthodes de répartition de données [Dewitt 92]

☛ **Approches :**

- *Partitionnement total (Full declustering)*
- *Partitionnement partiel (Partial declustering)*

☛ **Méthodes :**



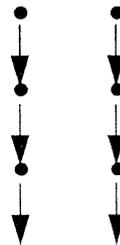
## 5. Niveaux, formes et types de parallélisme

- ☛ *niveaux de parallélisme : intra-requête, inter-requête.*
- ☛ *formes du parallélisme : intra-opération, inter-opération.*
- ☛ *types du parallélisme :*

*Pipeline*



*indépendant (partitionné)*

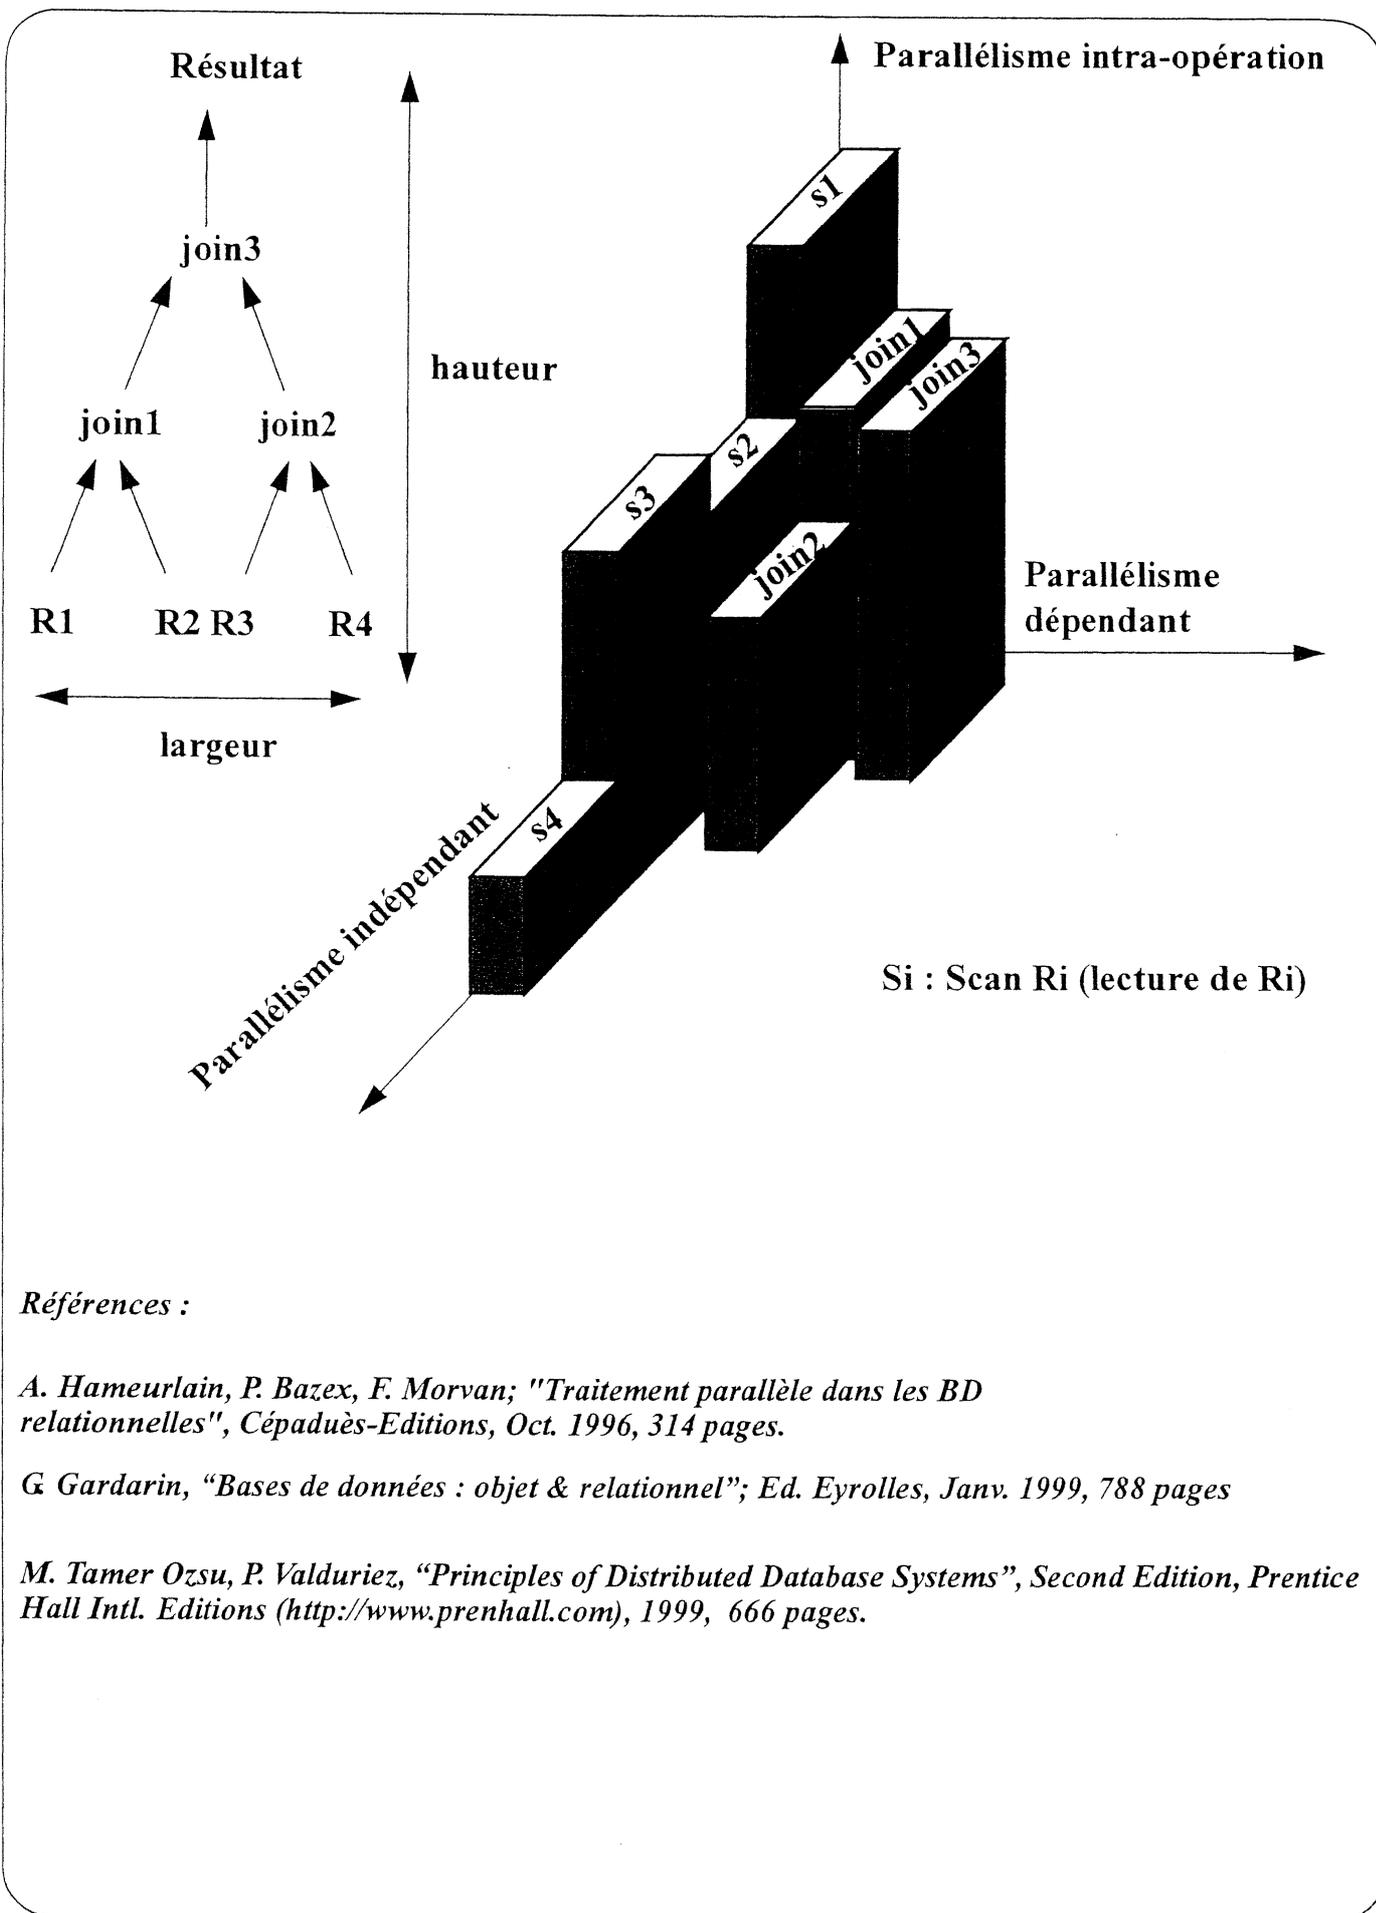


*(a) Pipeline : Chaque fois que 2 opérations échangent les données*

- +** *Evite de stocker des résultats intermédiaires*
- *Efficacité limitée : Chaîne de pipeline, fonctions,..*

*(b) Parallélisme indépendant*

- *Distribution des données*
- *Eclater l'opération en sous-opérations*
- +** *Sans communication et contrainte de synchronisation*
- *Répartition des données (équilibrer la charge de travail)*



**Références :**

A. Hameurlain, P. Bazex, F. Morvan; "Traitement parallèle dans les BD relationnelles", Cépaduès-Éditions, Oct. 1996, 314 pages.

G Gardarin, "Bases de données : objet & relationnel"; Ed. Eyrolles, Janv. 1999, 788 pages

M. Tamer Ozsü, P. Valduriez, "Principles of Distributed Database Systems", Second Edition, Prentice Hall Intl. Editions (<http://www.prenhall.com>), 1999, 666 pages.

### III. Parallélisation des opérateurs relationnels

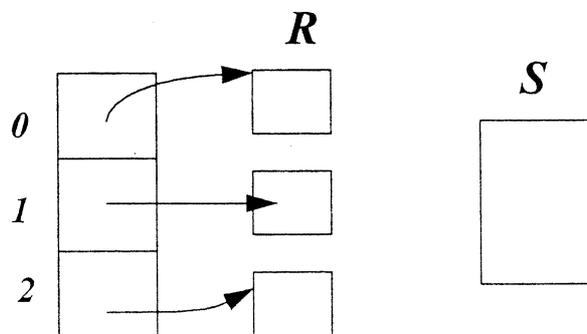
#### 1. Algorithmes de Jointure dans un contexte centralisé

☛ **Jointure par Produit Cartésien** :  $R \bowtie S$

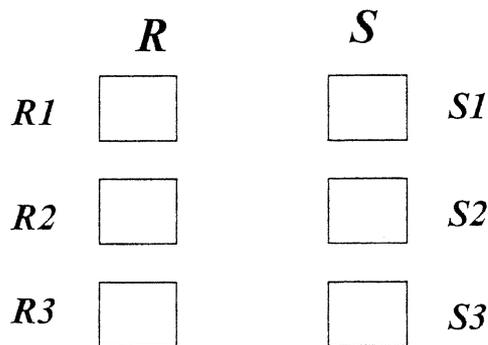
Chaque tuple de  $R$  est comparé avec chaque tuple de  $S$

☛ **Jointure par hachage**

• **Simple** : Build ( $R$ ) {table de hachage} ; Probe ( $S$ )



• **Hybride** : Fragmenter (découper)  $R$  avec une fonct.  $F$ ;  
 Fragmenter (découper)  $S$  avec une fonct.  $F$ ;  
 Pour  $i=1$  à  $n$  faire  $R_i \bowtie S_i$  (hachage simple)



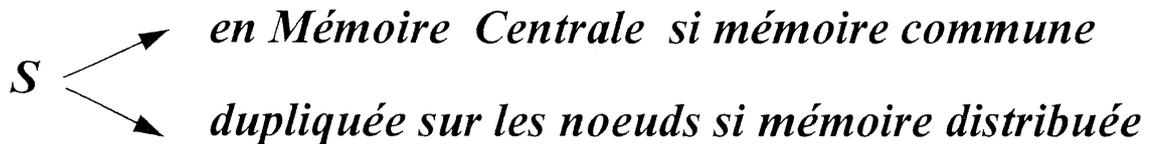
☛ **Jointure par Tri-Fusion**

- (1) Trier  $R$ ;
- (2) Trier  $S$ ;
- (3) Fusion;

## 2. Algorithmes de Jointures parallèles [Val 84] [Sch 89]

### ☛ Jointure par produit cartésien [Val 84]

*R est répartie sur les disques des processeurs*



### ☛ Jointure parallèle par hachage [Sch 89]

*R et S réparties sur les disques des processeurs  
avec une fonction F1*

- *Simple*

*build (Ri) avec une fonction F2*

- *Hybride*

*Ri et Si fragmentées (découpées) avec une fonct. F2  
build (Rij) avec une fonction F3*

### ☛ Jointure par Tri-Fusion [Val 84][Sch 89]

- |                                  |   |
|----------------------------------|---|
| <i>(1) Répartir (R, S, d)</i>    | <i>(1) Répartir R avec une fonction de F1</i> |
| <i>(2) Tri parallèle (log d)</i> | <i>(2) Répartir S avec une fonction de F1</i> |
| <i>(3) Fusion centralisée</i>    | <i>(3) Tri-Fusion en parallèle</i>            |

*Répartition d'une relation sur les disques des processeurs (F1)*

*≠*

*Construction des paquets/table hachage de données (F2/F3)*

### 3. Degré de parallélisme intra-opération : Méthode de détermination du nombre de processeurs pour une exécution parallèle

#### ☛ Motivations

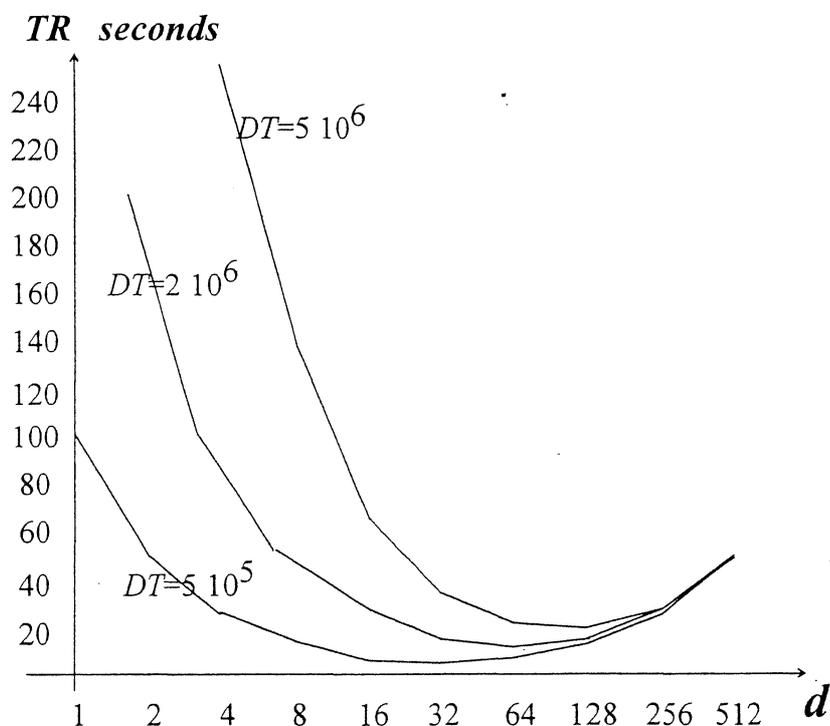
$$TR(d)_Q = A.d + B/d$$

$R = 10^6$  tuples;  $msg = 1$  ms;  $trf = 5 \mu s$ ;  $t = 0,2$  ms;  $p (=h)=100$

$t$  : temps pour produire un tuple,

$trf$  : temps pour transférer un tuple,

$msg$  : temps pour envoyer un message



Temps de réponse en fonction du nombre de processeurs

Si  $DT = 5 \cdot 10^5$  tuples alors le minimum RT est atteint pour  $d = 32$

Si  $DT = 2 \cdot 10^6$  tuples alors le minimum RT est atteint pour  $d = 64$

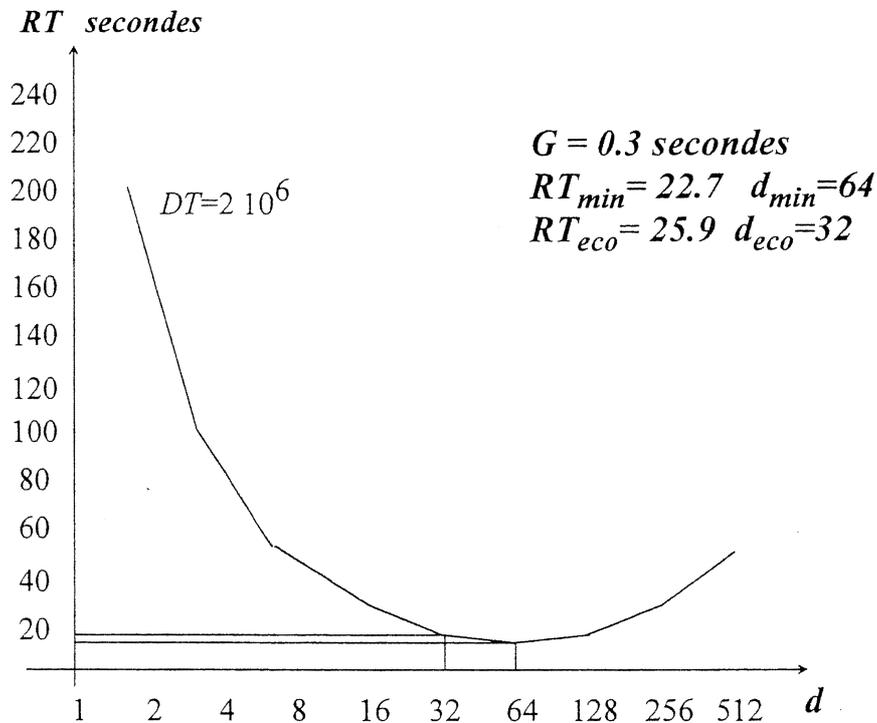
Si  $DT = 5 \cdot 10^6$  tuples alors le minimum RT est atteint pour  $d = 128$

#### ➔ Méthode d'estimation de DT

**DT:** Le nombre de tuples déduits par : une fermeture transitive  
ou une fermeture externe

## ☛ Détermination du nombre de processeurs économique

$$\Delta t = |RT_{min} - RT_{acc}| \implies \Delta d = d_{min} - d_{eco}$$



**G: seuil de rentabilité (break-even point)**

- **Définition de  $D_{eco}$ :**

(i)  $TR(d_{eco}) - TR(d_{eco}+1) < G$  ;

(ii)  $TR(d_{eco}-1) - TR(d_{eco}) \geq G$ .

- **Méthode de recherche :**

*Approche dichotomique dans  $[1, d_{max}]$*

$d_{max}$  : le nombre total de la machine cible

$M =$  milieu de  $[1, d_{max}]$

Si  $TR(M-1, R, S, p) - TR(M, R, S, P) < G$       ➔  $[1, M-1]$

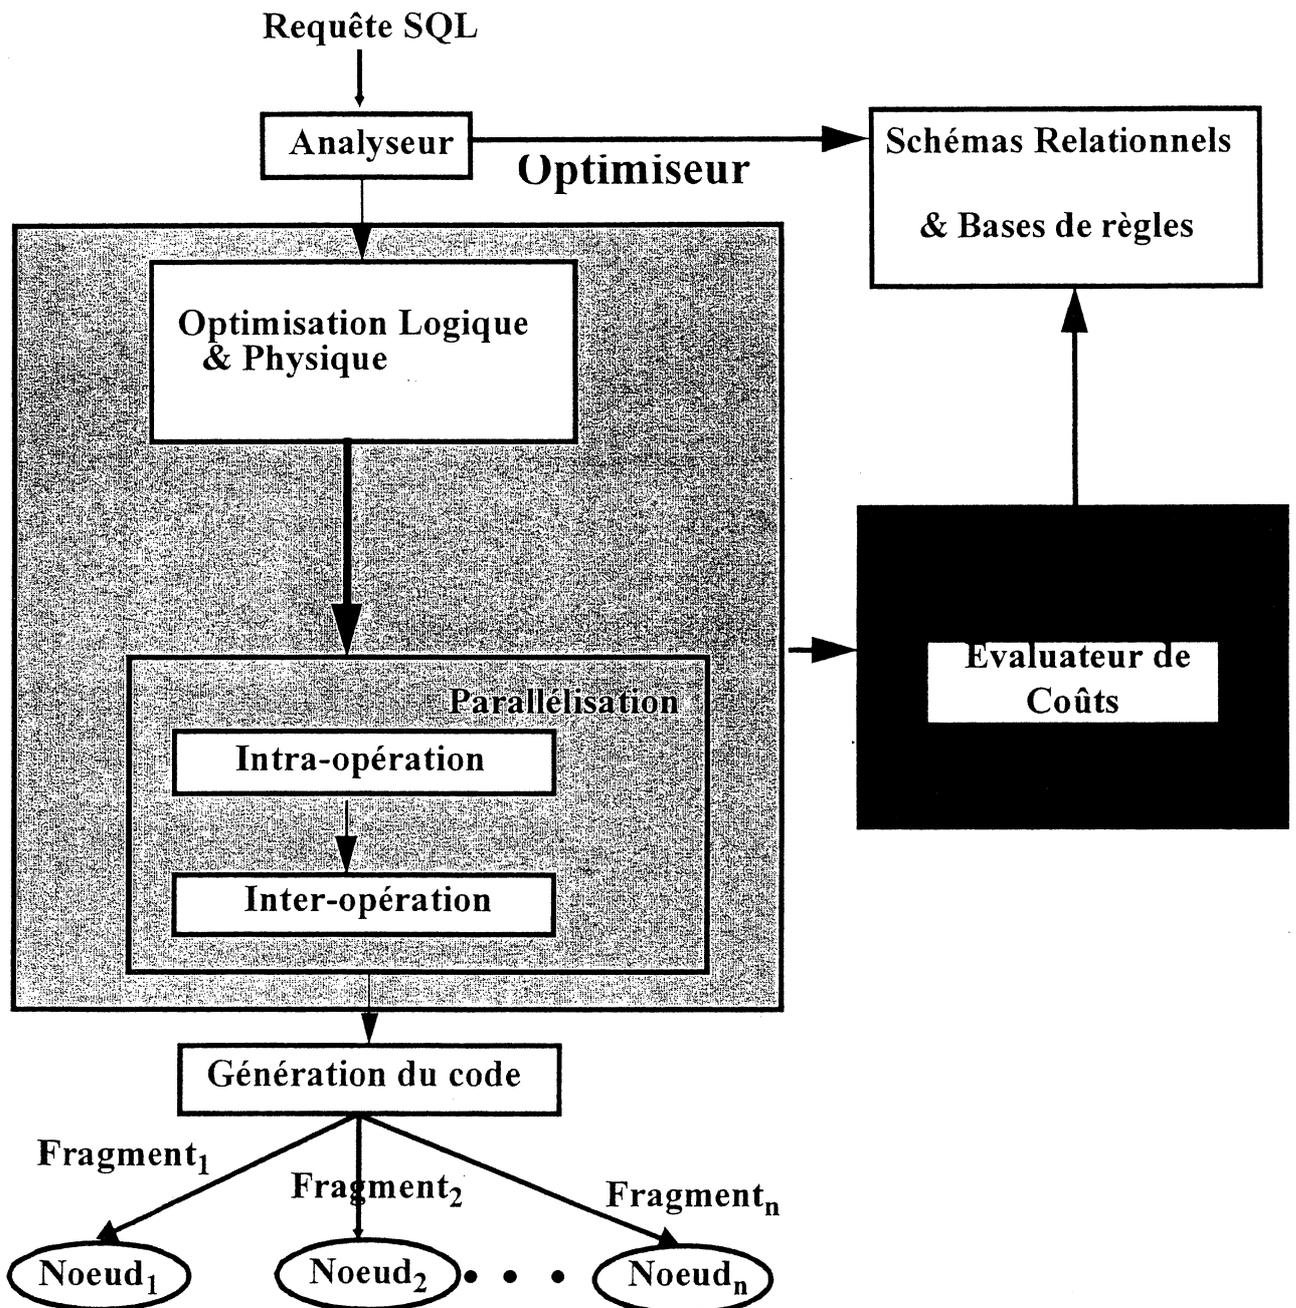
Si  $TR(M-1, R, S, p) - TR(M, R, S, P) \geq G$       ➔  $[M, d_{max}]$

**P : nombre de processeurs de l'opération successeur (communi.)**

## *IV. Méthodologies d'optimisation - parallélisation de requêtes décisionnelles*

### *1. Introduction*

#### *• Architecture d'un compilateur de requêtes SQL*



#### *• Optimiseur - Paralléliseur - Alloc. Res.*

☛ *Problème de l'optimisation de requêtes [Gan 92]*

$q \in Q, p \in PE$  (Plans d'exécution), Coût  $(q)_p$  :

⇒ *trouver le PE calculant  $q$  tel que le coût  $(q)$  est minimal*

◆ *Coût  $(q) = \text{Min (Temps Rep.)} \& \text{Max (Capacité du Système)}$*

☛ *Optimiseur =  $\langle S, E, C \rangle$*

- *S : Stratégies de recherche = {Optim. Physique, Parallélisation}*
- *E : Espaces de recherche = { Arbres linéaires et arbres bushy }*
- *C : Evalueur de coûts =  $\langle$  Environnement du système parallèle, Métriques  $\rangle$*

⇒ *Stratégies de Recherche :*

◆ *Optimisation Physique (monoprocasseur):*

- *Choix du meilleur Alg. de jointure &*

- *Génération d'un ordre efficace des opérateurs de jointure [Swa 88, Ioa 89, Lan 91,...]*

• *Stratégies Enumératives:*

- *Breadth-First (System R [Sel79]),*

- *Depth-First (AH, AH\*)*

• *Stratégies Aléatoires:*

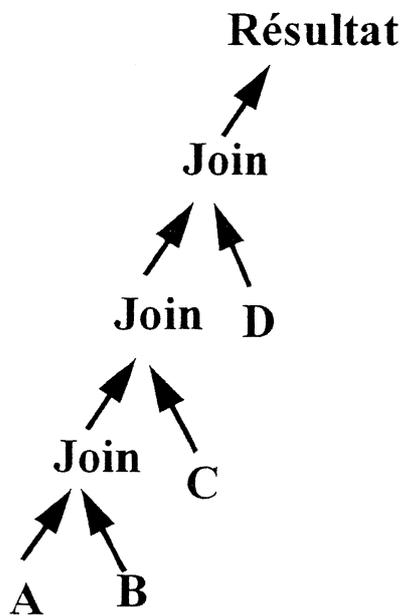
- *Iterative Improvement II*

- *Simulated Annealing SA*

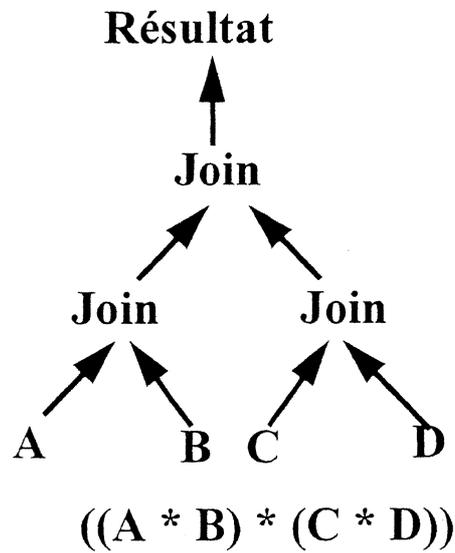
◆ *Parallélisation (Multiprocasseur) :*

*Scheduling (// Extraction) & Allocation de Ressources*

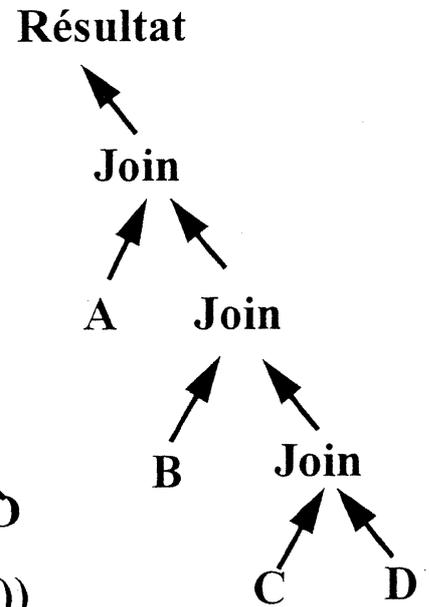
⇒ *Espaces de recherche :*



$((((A * B) * C) * D))$   
*Arbre linéaire gauche*



$((A * B) * (C * D))$



$(A * (B * (C * D)))$   
*Arbre linéaire droit*

## 2. *Stratégies de parallélisation des opérations d'une requête*

### ☛ *Objectif :*

*Engendrer un plan d'exécution PE parallèle (~ Oprimal)*

### ☛ *Approches : < mono-phase et à deux phases >*

$\Phi_1$  : *Génération d'un PE sans considerer les ressources*

$\Phi_2$  : *Allocation des ressources (proche de l'optimale)*

⇒ *Approche mono-phase :  $\{\Phi_1 * \Phi_2\}^*$*

⇒ *Approche à deux phases :  $\{\Phi_1 ; \Phi_2\}$*

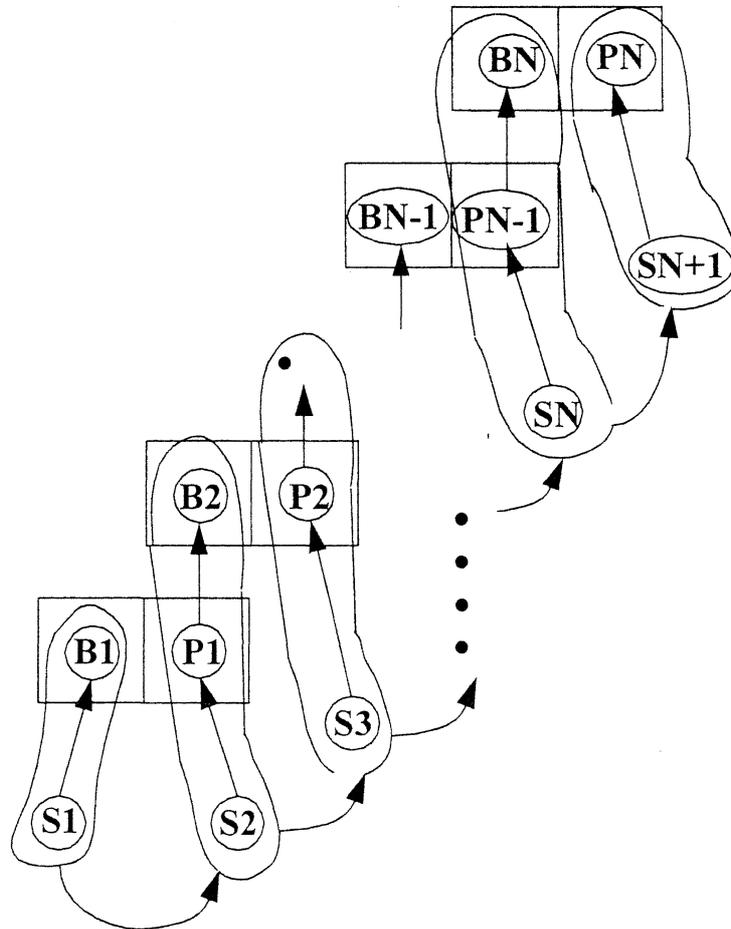
### ☛ *Approche mono-phase : $\{\Phi_1 * \Phi_2\}^*$*

➡ *Extension des Stratégies de recherche à l'optimisation de requêtes parallèles.*

- *Extension du Modèle de Coûts = Capture tous les aspects du < Parallélisme & Alloc. Res. >*

➡ *Allocation de ressource : <Memory>*

### 3. Approches mono-phase (Gamma [SCH90] & DBS3 [ZIA 93])



**SEQ**

*PIPE Scan S1 - Build J1 ENDPipe;*

*PIPE Scan S2 - Probe J1 - Build J2 ENDPipe;*

*PIPE Scan S3 - Probe J2 - Build J3 ENDPipe;*

•••••

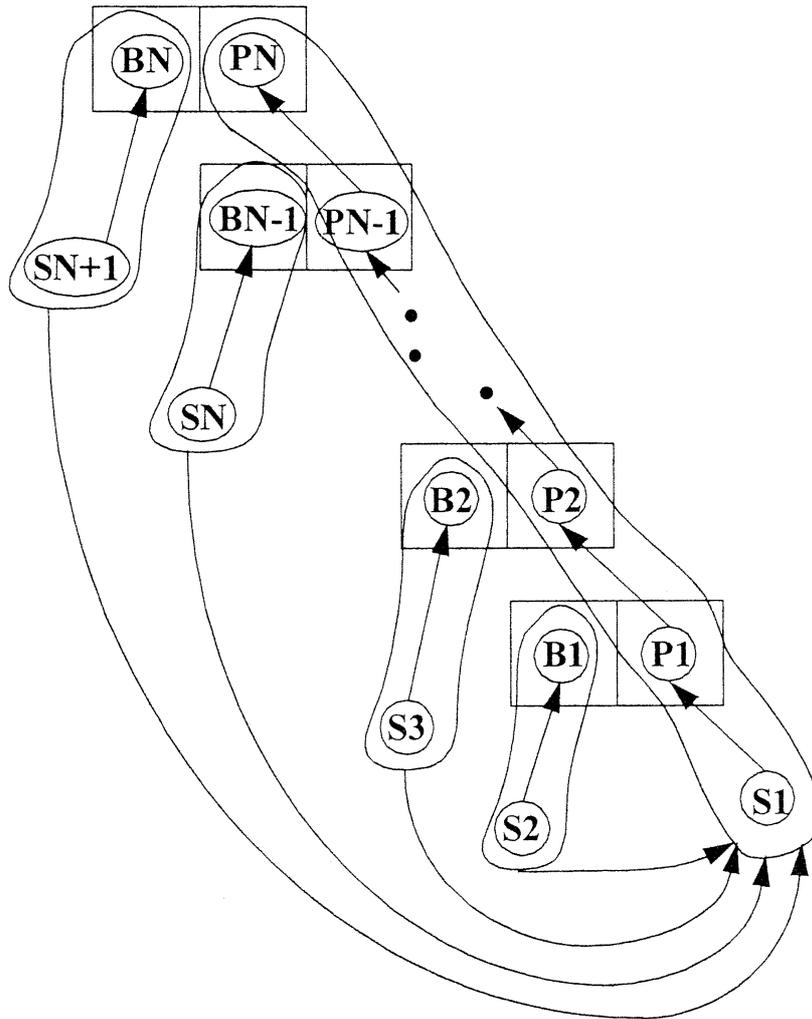
*PIPE Scan SN - Probe JN-1 - Build JN ENDPipe;*

*PIPE Scan SN+1 - Probe JN ENDPipe;*

**ENSEQ**

**SCAN (R) = Sélection (R) + Répartition (R)**

**Arbre linéaire gauche**



*SEQ*

*PAR*

*PIPE Scan S2 - Build J1 ENDPipe*

*PIPE Scan S3 - Build J2 ENDPipe*

*PIPE Scan S4 - Build J3 ENDPipe*

••••

*PIPE Scan SN+1 - Build JN ENDPipe*

*ENPAR*

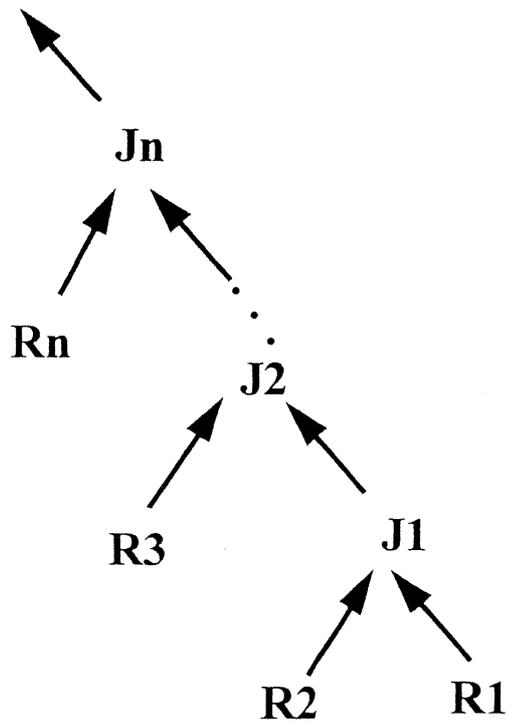
*PIPE Scan S1 - Probe J1 - Probe J2- ••• Probe JN ENDPipe*

*ENSEQ*

### Arbre linéaire droit

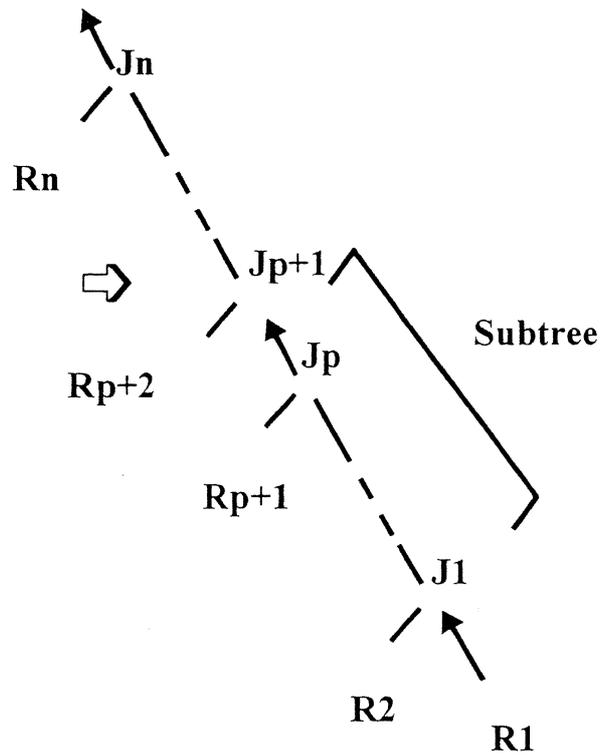
### Contention Mémoire [Sch90]

Résultat

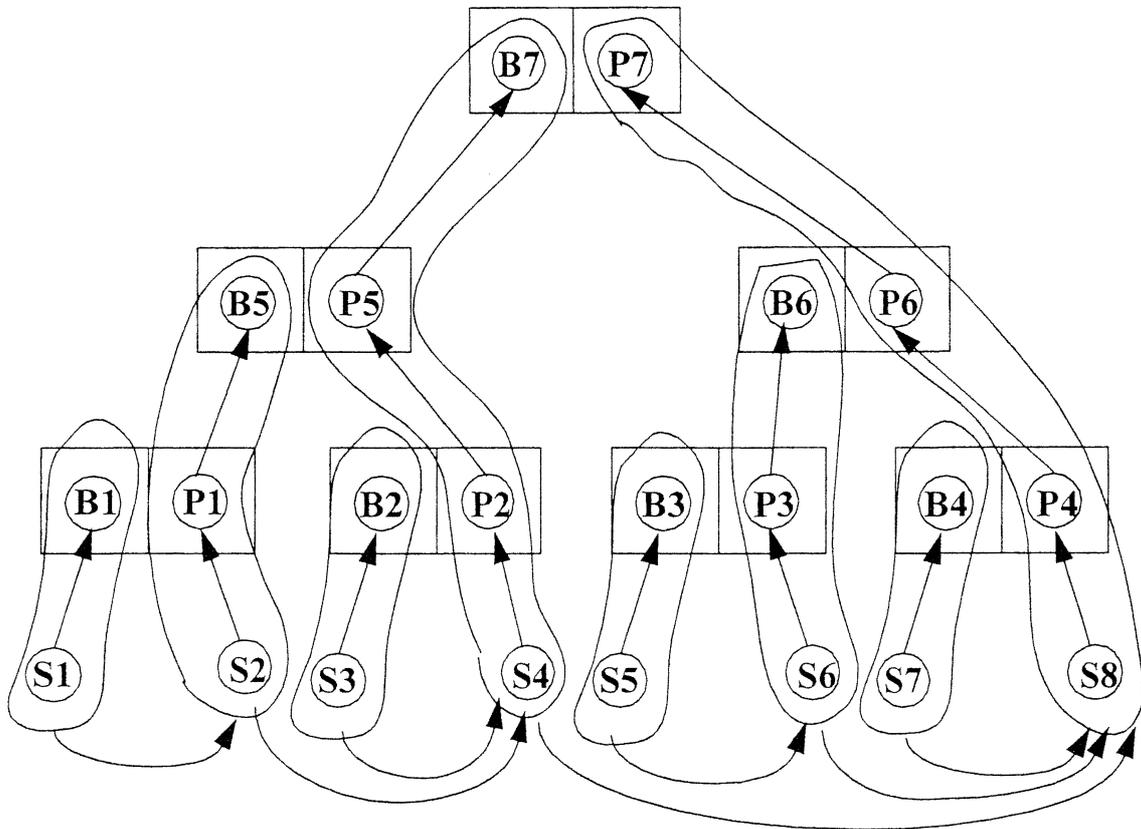


$(R_n * \dots (R_3 * (R_2 * R_1)))$   
*Right-Deep Tree*

Résultat



*Sliced Right-Deep Tree*



```

SEQ
PAR
  PIPE Scan S1 - Build J1 ENDPipe
  PIPE Scan S3 - Build J2 ENDPipe
  PIPE Scan S5 - Build J3 ENDPipe
  PIPE Scan S7 - Build J4 ENDPipe
ENPAR;
PAR
  PIPE Scan S2 - Probe J1- Build J5 ENDPipe
  PIPE Scan S6 - Probe J3 - Build J6 ENDPipe
ENDPAR;
PIPE Scan S4 - Probe J2 - Probe J5 -Build J7 ENDPipe
PIPE Scan S8 - Probe J4 - Probe J6 - Probe J7 ENDPipe
ENSEQ
    
```

### Arbre ramifié (Bushy)

**4. Approches à deux phases [Hon92, Has 95, Garo 96/97, Kab 98...]**

☛ **Principe** :  $\Phi_1$  ;  $\Phi_2$

$\Phi_1$  : Génération d'un PE seq. optimal sans considerer les ressources (Opt. Physique)

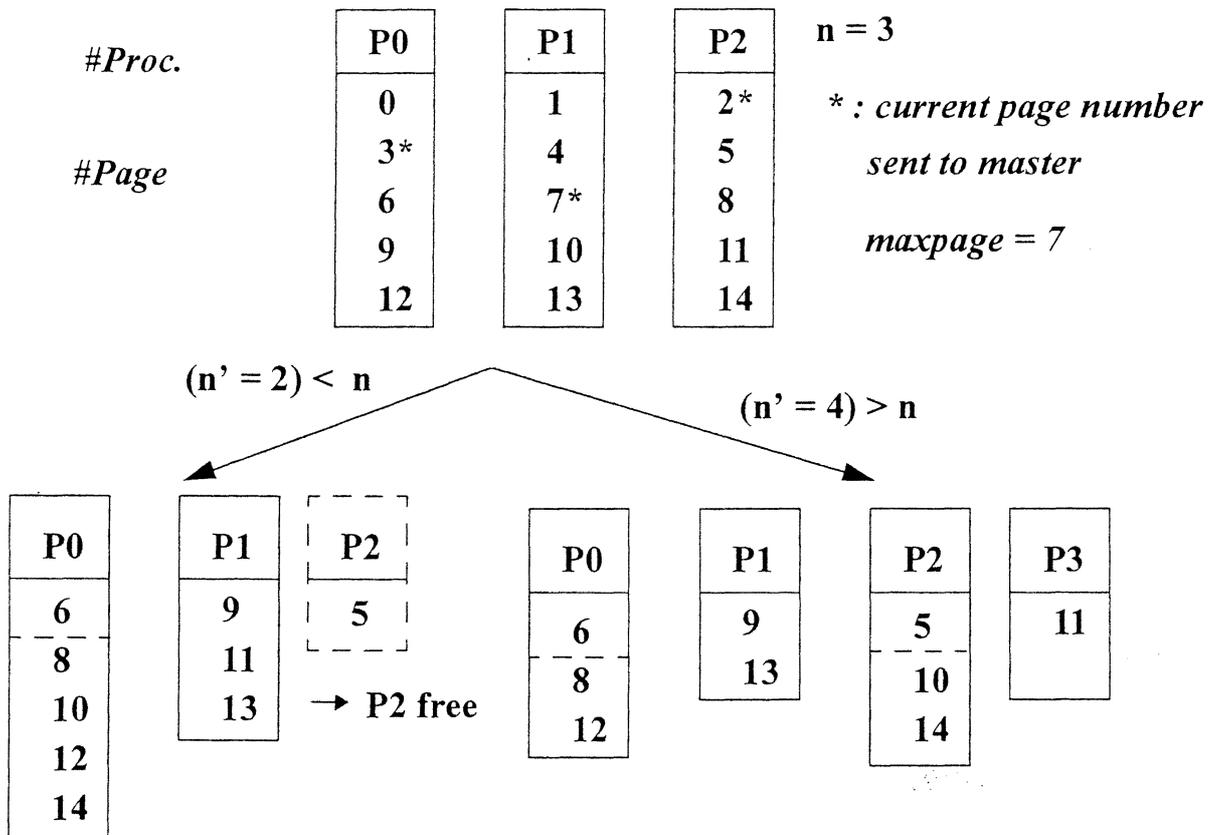
$\Phi_2$  : Allocation de ressources

$\Phi_2$  : <Extraction du Parallélisme ; Allocation de Ressource>

☛ **Méthodes d'ajustement du degré de parallélisme**

M1 : Page Partitioning (Répartition circulaire)

☛ Ces méthodes sont exploitées par l'alg. d'ordonnancement adaptatif/point d'équilibre IO-CPU



**M1 : Page Partitioning Parallelism Adjustment**

## 5. Formalisation du processus de placement [And88, Cos93]

### Définition Informelle

**“Placer” une application sur une architecture parallèle**

*i.e.*

**Allouer physiquement les processeurs de l'architecture parallèle aux tâches de l'application de manière à optimiser une fonction de coûts en respectant des contraintes d'allocation, de façon à garantir une utilisation quasi-optimale des ressources.**

**1. Définition formelle : Un placement est une application  $\text{alloc}$  qui associe un processeur à une tâche :**

$$\text{alloc} : T \rightarrow P / \forall t \in T, \exists q \in P, \text{alloc}(t) = q$$

avec

**T**, l'ensemble des  $n$  tâches de l'application à placer et

**P**, l'ensemble des  $p$  processeurs de l'architecture parallèle

\* Nombre de placements possibles :  $p^n$

- ☛ **Approches :**
- ◆ **Strategies Enumeratives**
  - ◆ **Strategies Approximatives/Aleatoires**

## 2. Hypothèses :

*{Type d'archi.//, Nature des Proc., RI (f/v),  
Mode d'exploitation, Type de placement}*

## 3. Contraintes d'allocation

*C0 : Contrainte de localité des données :*

*Scan<sub>i</sub> s'exécute là où se situent les données.*

*C1 : Contrainte de localisation des données :*

*Alloc(Build<sub>j</sub>) = Alloc(ProbeX<sub>j</sub>)*

*C2 : Contrainte de parallélisme indépendant :*

*Alloc(T<sub>i</sub>) ≠ Alloc(T<sub>j</sub>), si i ≠ j et*

*∃ t / T<sub>i</sub> et T<sub>j</sub> s'exécutent simultanément*

*C3 : Contrainte de parallélisme pipeline :*

*Alloc(ProbeX<sub>j</sub>) ≠ Alloc(pred(ProbeX<sub>j</sub>)) et*

*Alloc (Build<sub>j</sub>) ≠ Alloc(pred(Build<sub>j</sub>))*

## 4. *Prise en compte du parallélisme intra-opération*

*⇒ Allocation logique d'un ensemble de processeurs  
à chaque tâche du GdD*

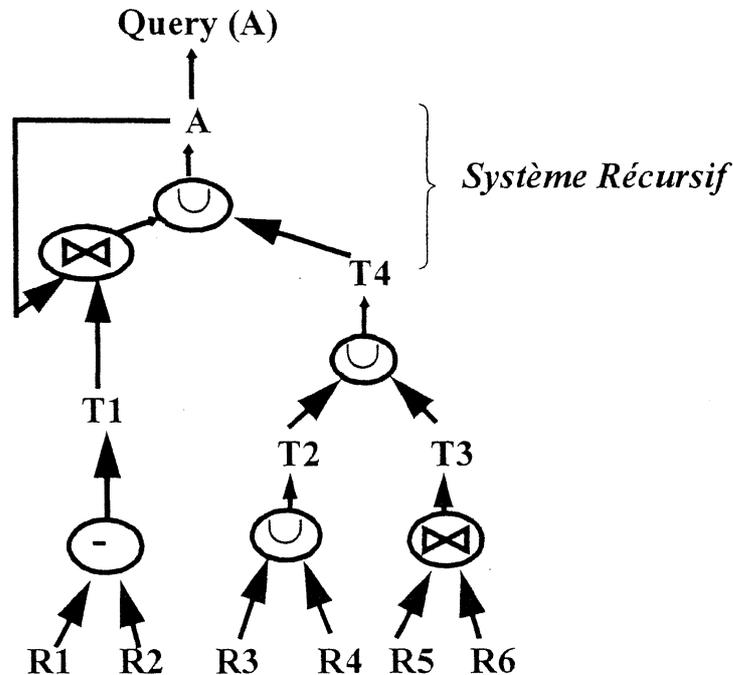
## 6. Synthèse des méthodes d'optim. de req. parallèles

**Table 1: Paramètres permettant une aide à la décision dans le choix d'une approche d'optimisation**

<i>Approche</i>		
<i>Paramètres</i>	<i>Mono-phase</i>	<i>Deux-phases</i>
<i>Espace de rech</i>	<i>Plus large</i>	<i>Plus réduit</i>
<i>Strat. d'opti. //</i>	<i>Extesion d'une strat. opt. phys.</i>	<i>Conception d'une strat.</i>
<i>Coût d'opti. //</i>	<i>Plus élevé</i>	<i>Moins élevé</i>
<i>Modèles de coûts</i>	<i>Extension d'un MC :</i>	<i>MC1 + MC2</i>
<i>Implémentation</i>	<i>Plus difficile</i>	<i>Moins difficile</i>

## 7. Performance des Formes de Parallélisme

- Architecture à Mémoire Distribuée
- Benchmark [Bit 83, Gra93], & Paramètres [Sch 90, Val 88]



- Jointure par Hachage simple;

$$TRL (T \leftarrow R \bowtie S) = T_{ef} + T_d + T_{com} \quad \text{Où}$$

$$T_{ef} = (|R|/d).th + ((|R|/d) + (|S|/d)).CR + (|R|/d/q).( |S|/d).CJO + |T|.I + |T|/d.CW$$

temps build + temps de lecture + temps de comparaison +  
temps de déplacement + temps d'écriture

$$T_d = (|T|/d).th \quad \text{and} \quad T_{com} = ((|T|/d).trf + p.msg). \lceil d/p \rceil$$

|R| : Nombre de Tuples de R=10<sup>6</sup>

||R|| : Nombre de pages de R

th : Temps pour répartir 1 tuple = 3 μs

CR : Temps de lect. 1 page (18KB)= 8 ms

CW : Temps d'écriture 1 page= 16 ms

I : Temps pour déplacer un tuple

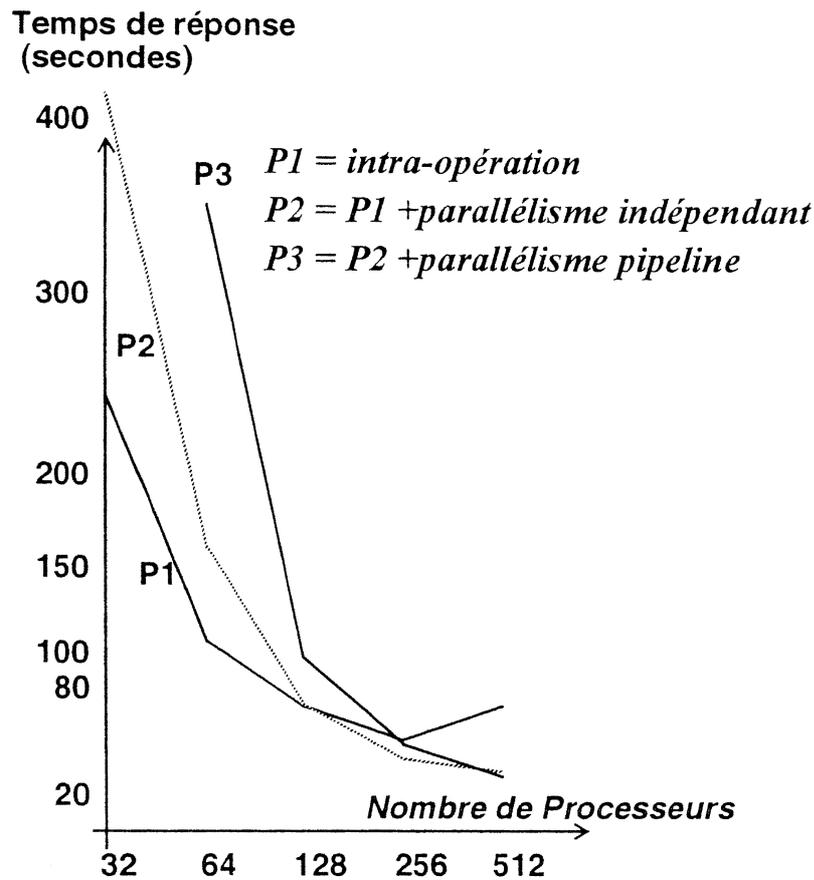
CJO : Temps pour joindre 2 pages non triées

d : Nombre de proc. de l'opér. source

p : Nombre de proc. de l'opér. destination

Trf : Temps pour transf. 1 tuple

msg : Temps pour envoy. 1 message



◆ *Efficacité du Parallélisme :*

- *Intra-opération avec un petit NB de processeurs*
- *Pipeline avec un grand NB de processeurs*

➔ *Coûts de Communication*

## ***V. Optimisation des Coûts de Communication***

### **◆ Optimisation Logique :**

⇒ Réduire le volume de données manipulées

☛ Approche : Application des règles de Transformation des Arbres Algébriques

{Join Select --> Select Join ; Union Select --> Select Union,....}

### **◆ Optimisation Physique : Ordonnement des jointures**

⇒ Réduire les E/S

☛ Approche : Exploitation des accélérateurs (clés et index)

### **◆ Parallélisation inter-opération (Ordonnement parallèle & Placement):**

→ Coûts de comm. Inter-opération

- Limiter le volume de données transférées

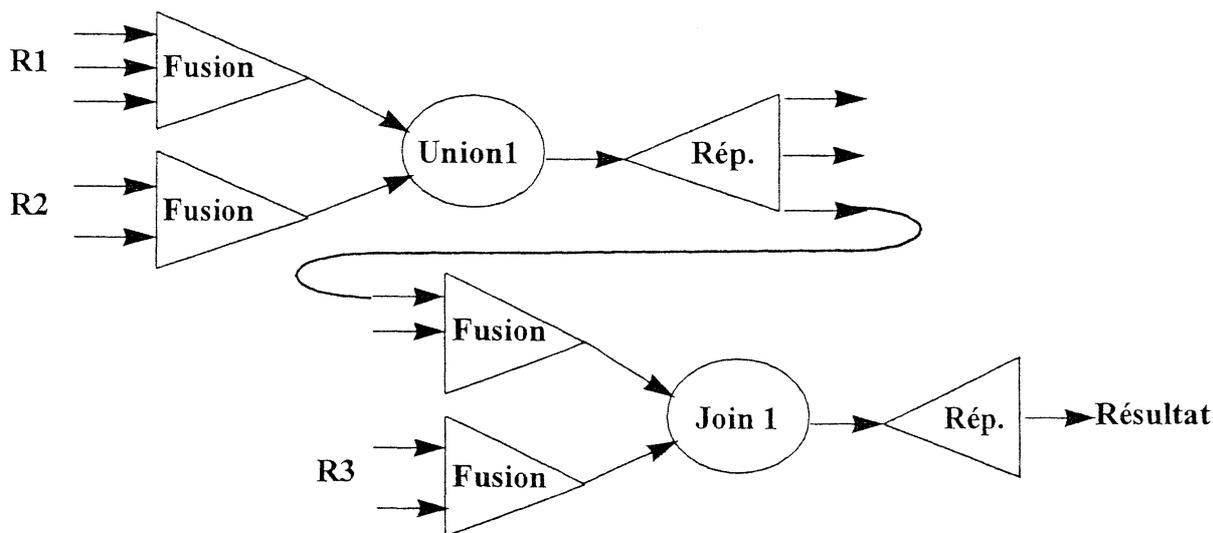
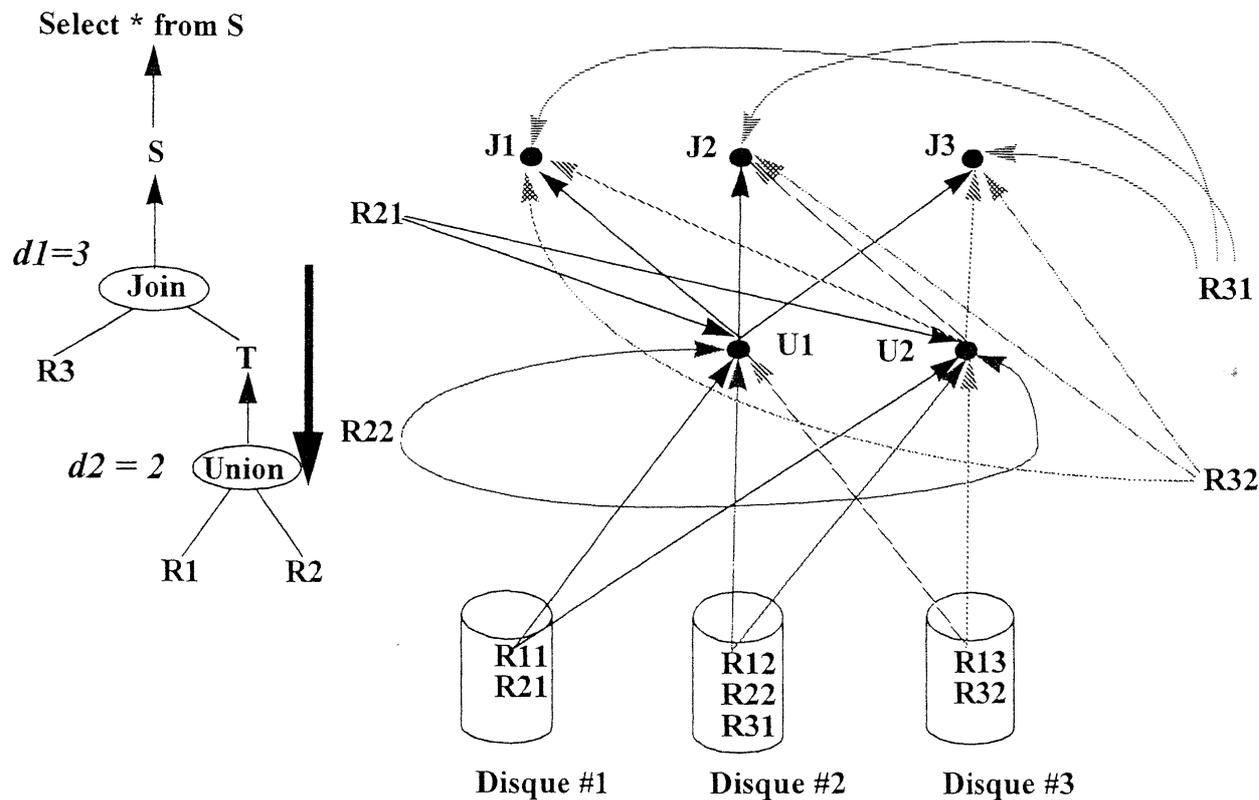
→ Coûts de com. Inter-processeur

- Minimiser les temps de transfert inter-proc. (Topo. RI)
- Minimiser l'impact des temps start-up pipeline

# 1. Minimisation des Coûts de Com. Inter-opération

➔ Coûts de la Redistribution de données > Coût d'Exécution

Méthodes : Propagation  $\langle \text{Attr\_répart.}, \text{Nb\_proc} \rangle$  [Ham 93]  
 Coloriage d'un arbre [Has 95]

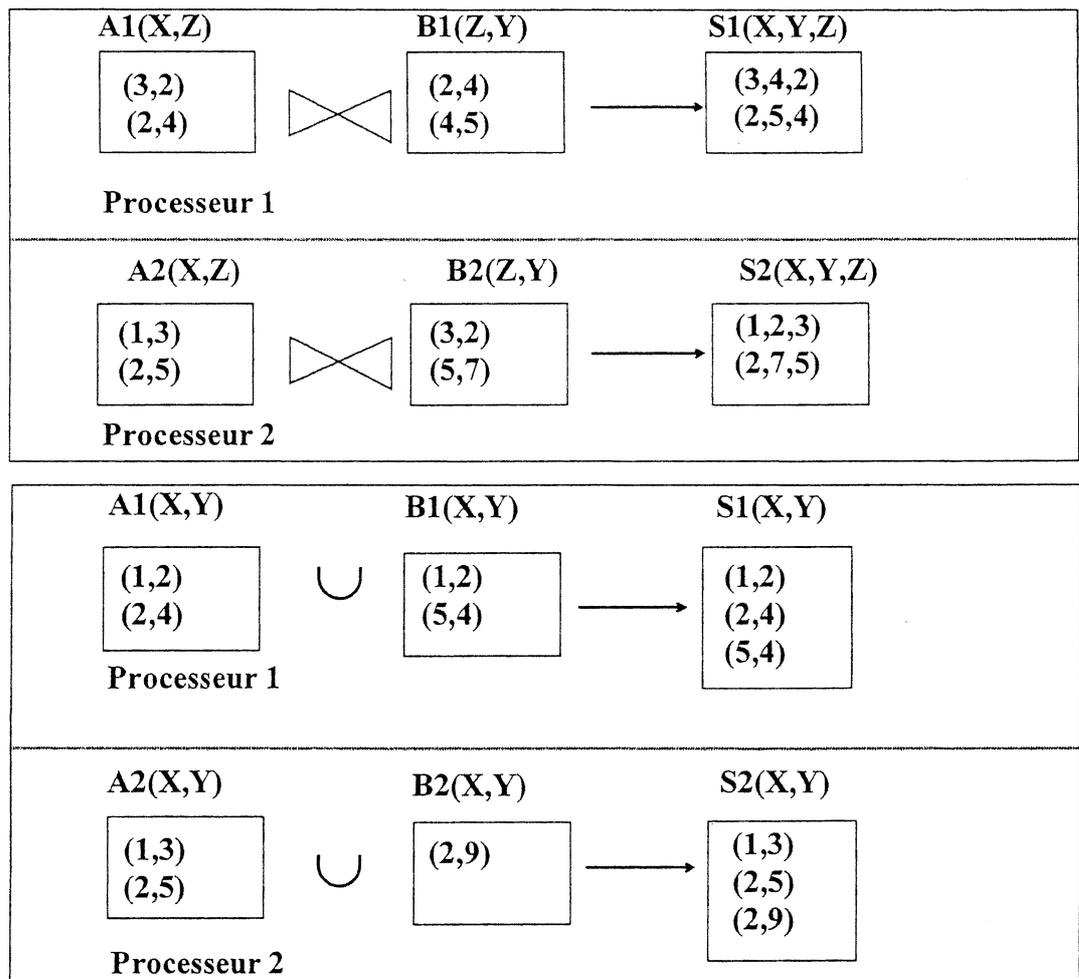


⇒ NB important de messages de données et de contrôle

### A. Conditions de Redistribution des données

- ◆ **Fonction de répartition** : Une relation produite par une opération n'est pas consommée avec la même fonction de répartition par l'opération succ.
- ◆ **Attribut de répartition** : Une relation produite est consommée par l'opération successeur avec un attribut de répartition différent.
- ◆ **Allocation de processeurs**: Les nombres de processeurs alloués à une opération et son successeur sont différents.

### B. Classe des Opérations : C1, C2



**C. Méthode de Propagation :**  
*Attributs de Répartition & Nombre de Processeurs*

- **Hypothèse : même fonction de répartition**

Pour chaque  $OP(i) \in$  graphe de la requête faire

$E1 : OP(i) \Rightarrow$  (meilleur Algorithme,  $NB\_P$ ,  $TRL$ )

☛ **Evaluateur de coûts :**

(i) Recherche le meilleur Algorithme ( $TR$ )

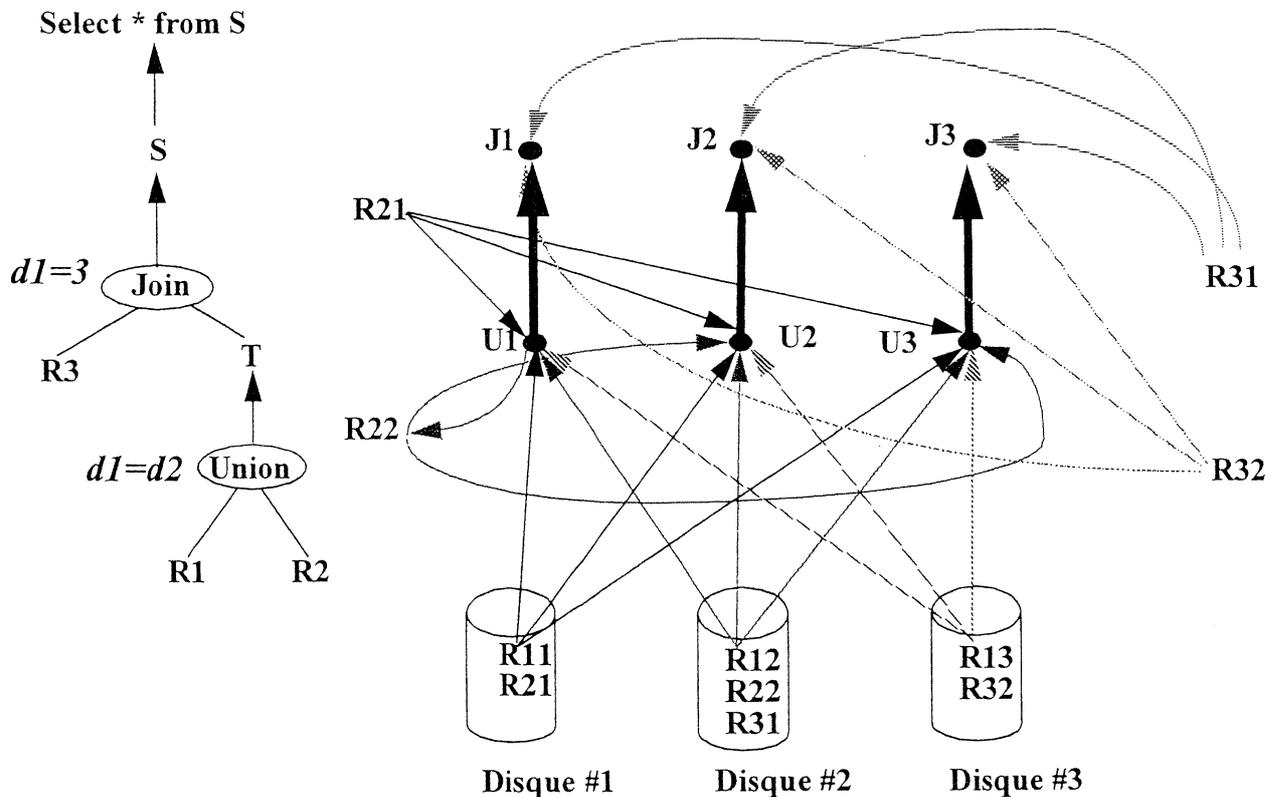
→ Table de décision ( $\setminus relations \setminus$ )

(ii) Détermine : ( $NB\_P$ ,  $TRL1$ )

$E2 : Propager$  ( $Attr\_Succ$ ,  $NP\_Succ$ ) si les 2 cond. suivantes sont vérifiées :

(1)  $OP(i) \in C2$  ou  $Attr\_Succ$  correspond à un attribut de jointure pour  $OP(i)$

(2) le processus de propagation améliore le  $TRL$ .



## VI. Conception d'un Evalueateur de Coûts

### ☛ Motivations

➔ *Optimisation physique: Choix d'une Stratégie de recherche*

◆ *Algorithmes Enumératives (exacts): RLD, AH, AH\**

◆ *Algorithmes Aléatoires : AI, RS, TRS et Génétiques*

➔ *Détermination du degré du parallélisme :*

◆ *Intra-opération : Choix d'un algorithme (seq/par)*

◆ *Propagation des attr. de répartition et du nb Procs*

➔ *Placement des opérations :*

◆ *fonction de coût à minimiser*

### ☛ Modèles de Coûts classiques :

— *Ne prennent pas en compte l'env. / Modèles de Coûts*

— *Ne sont pas compatibles avec les autres systèmes*

➔ *Séparer l'optimiseur et l'évaluateur de coûts [And 91]*

*Raisonnement*  *Connaissances*

• *Optimisation physique*

• *Détermination du nombre processeurs économique*

• *Optimisation de requêtes récursives*

• *Optimisation des communications de données*

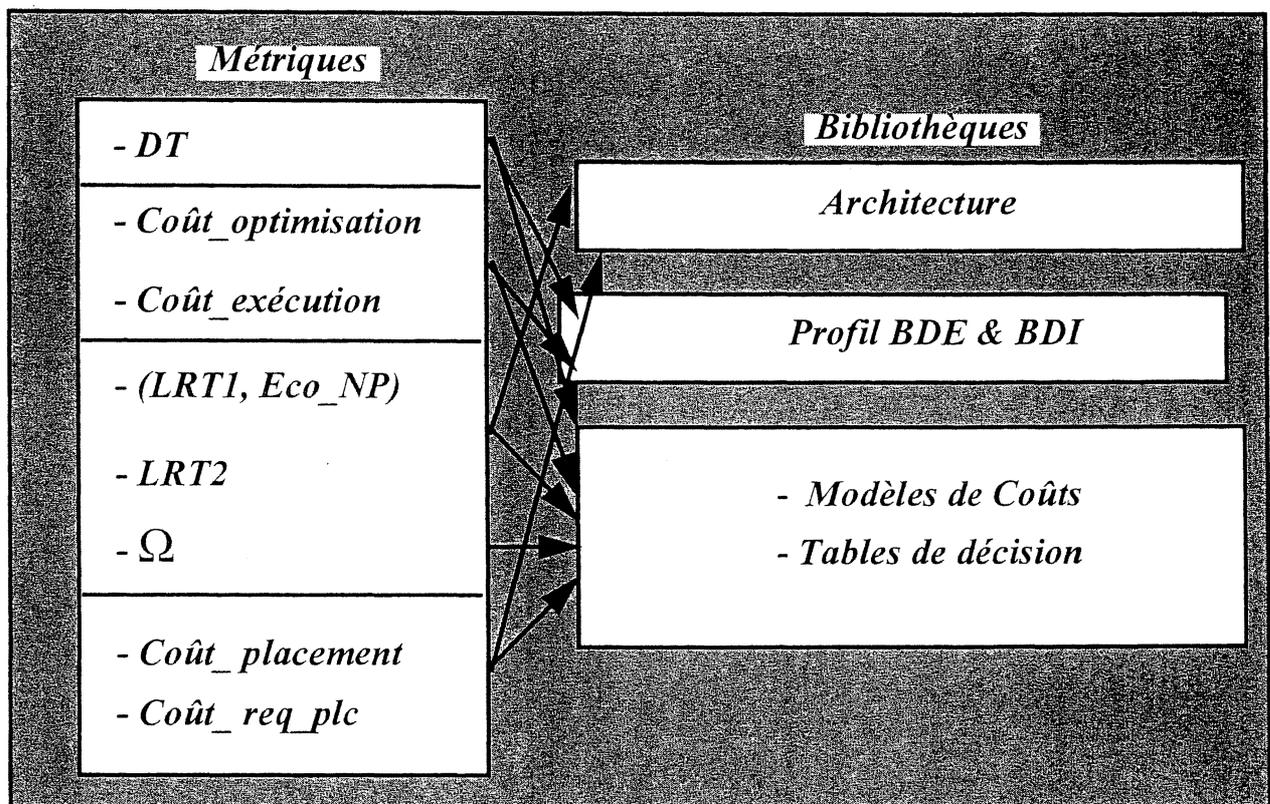
➔ *EC = < Métriques + Librairies >*

☛ **Avantages :**

- ◆ *Extensibilité : Méthodes d'Accès, Algo., Profile BD,...*
- ◆ *Flexibilité : Ajout de nouvelles métriques*
- ◆ *Adaptabilité : aux diff. machines BD.*

☛ **Evaluation des métriques :**

➔ *Représentation de l'environnement* ⇨ *Bibliothèques*



☛ **Métriques de l'Évaluateur de Coûts**

- ◆ *Nombre de tuples déduits : DT*
- ◆ *Coût d'optimisation :  $T_{opt}$*
- ◆ *Qualité d'optimisation (trade-off)*
- ◆ *Nombre de processeurs et TRL1*  
*OP(i) ⇨ meilleur algo. NBP\_ECO, TRL*  
 (i) *Recherche du meilleur alg. (table de décision 1)*  
 (ii) *Détermination (NBP\_ECO, TRL1)*

- ◆ *Propagation des attr. de répartition et du NBP\_ECO*
  - ↳ *Table Décision 2 ( $|R_i|$ , NBPROC) ⇨ Algo.*

- ◆ *Placement des opérations : fonction de coût*

#### 4. *Représentation de l'environnement d'une machine parallèle*

##### ↳ *Profile de la BD*

- ◆ *Cardinalité des relations de base*
- ◆ *Valeur minimale et maximale d'un attribut*
- ◆ *Nombre de valeurs distinct d'un attribut*
- ◆ *Taille d'un attribut*
- ◆ *Fin, Fout, base*

##### ↳ *Modèles de Coûts*

- ◆ *Fonctions de coûts des métriques (DT,...)*
- ◆ *Tables de décision*

##### ↳ *Architecture*

- ◆ *Type d'architecture (Type Mémoire, Type réseau, Type cpu, Type système, nombre de processeurs)*
- ◆ *Mémoire (taille mémoire , tps d'accès mémoire)*
- ◆ *CPU (tps d'une opération simple, tps de distribution)*
- ◆ *Système (taille d'1 page, tps lecture/écriture d'1 page)*
- ◆ *Réseau (tps pour envoyer 1 tuple, tps pour envoyer 1 message)*